

ROTEIRO DE AULA PRÁTICA

Engenharia de Requisitos para ML com GR4ML

Caderno de Exercícios do Grupo
Preencha os templates de cada fase durante a aula

Centro de Informática — CIn/UFPE
Especialização em Deep Learning · Disciplina: Engenharia de Software para IA

Grupo (nome dos integrantes)	Projeto da disciplina
Luis Eduardo Moreira Las Casas	Predição de Demandas
Thiago Augusto Souza do Nascimento	Predição de Demandas
Iuan Ferraz Souza	Predição de Demandas
Natália Michelinini Monteiro	Predição de Demandas
Gabriela Ladeira Nadaes	Predição de Demandas
Gabriel Dantas Leite	Predição de Demandas
Gabriel Lucena	Predição de Demandas

Links oficiais: https://www.cs.toronto.edu/~soroosh/gr4ml_language.html
https://www.cs.toronto.edu/~soroosh/gr4ml_toy.html

Como usar este caderno

Este material acompanha o roteiro de aula prática de Engenharia de Requisitos com o framework GR4ML (Goal-Oriented Requirements Engineering for Machine Learning). Cada fase da aula está organizada da mesma forma, para facilitar o acompanhamento:

-  **Ideia central** — uma explicação simples do que a fase/ passo quer resolver, sem jargão técnico.
-  **Exemplo** — um exemplo já resolvido, usando o caso de uma plataforma de streaming que quer reduzir cancelamento de assinaturas (nosso 'fio condutor' do início ao fim).
-  **Entregável** — a frase que diz exatamente o que vocês precisam ter em mãos ao final daquele passo.
-  **Espaço para preencher** — um template em branco para o grupo completar com o próprio projeto, durante a aula.
-  **Checkpoint** — um ponto de parada para o professor validar o progresso do grupo antes de seguir adiante.

Objetivo da atividade

Capacitar os alunos a elicitar, modelar e alinhar requisitos de negócio com decisões de design analítico e pipelines de dados utilizando o GR4ML, garantindo que o modelo de Machine Learning atenda a um valor real de negócio — e não apenas a uma métrica técnica isolada.

Cronograma sugerido

Fase	Duração	Conteúdo
Fase 0 — Alinhamento	20 min	Escopo do projeto, stakeholder principal e dor de negócio
Fase 1 — Business View	45 min	Atores, objetivos, indicadores, decisões e perguntas de negócio
Fase 2 — Analytics Design View	45 min	Tipo de análise, tarefas de ML, algoritmos, softgoals e métricas
Fase 3 — Data Preparation View	45 min	Fontes de dados, transformações e pipeline até o dataset final
Fase 4 — Dos modelos aos requisitos	30 min	Tradução dos modelos em Requisitos Funcionais, Não-Funcionais e de Dados

As três visões do GR4ML, em uma tabela

Visão	Pergunta que responde	Quem pensaria assim, na vida real	O que sai dela
1. Business View	Quem precisa de quê, e por quê?	Gestor / dono do produto	Diagrama Ator → Goal → Decision Goal → Question Goals
2. Analytics Design View	Que modelo resolve isso, com qual qualidade?	Cientista de dados	Tarefas de ML, algoritmos e métricas ligadas aos softgoals
3. Data Preparation View	De onde vêm os dados e como chegam prontos?	Engenheiro de dados	Pipeline de dados brutos até features prontas



FASE 0 — Alinhamento de Contexto

20 minutos · antes de abrir qualquer ferramenta de modelagem

Ideia central: antes de pensar em modelo ou algoritmo, o grupo precisa conseguir resumir o projeto em um parágrafo simples. Identifiquem claramente quem é o principal patrocinador (stakeholder) do projeto e qual dor de negócio motivou a criação do sistema de ML.



Exemplo (streaming)

- "O Gerente de Retenção de Clientes da plataforma quer reduzir o cancelamento de assinaturas, que hoje é decidido caso a caso sem nenhum critério preditivo, causando perda de receita recorrente."



ENTREGÁVEL DESTES PASSOS: Um parágrafo curto (3–5 linhas) descrevendo o stakeholder principal e a dor de negócio do projeto de vocês. Essa frase será a 'âncora' de todas as fases seguintes.



Espaço para o grupo preencher

Ideia central: A Diretoria de Supply Chain busca melhorar o planejamento de abastecimento das lojas diante das variações das vendas ao longo do tempo. O projeto utilizará dados históricos e variáveis relacionadas às vendas para prever as vendas semanais e apoiar decisões de abastecimento e disponibilidade de produtos.



FASE 0 — Alinhamento de Contexto

20 minutos · antes de abrir qualquer ferramenta de modelagem

Ideia central: antes de pensar em modelo ou algoritmo, o grupo precisa conseguir resumir o projeto em um parágrafo simples. Identifiquem claramente quem é o principal patrocinador (stakeholder) do projeto e qual dor de negócio motivou a criação do sistema de ML.



Exemplo (streaming)

- "O Gerente de Retenção de Clientes da plataforma quer reduzir o cancelamento de assinaturas, que hoje é decidido caso a caso sem nenhum critério preditivo, causando perda de receita recorrente."



ENTREGÁVEL DESTES PASSOS: Um parágrafo curto (3–5 linhas) descrevendo o stakeholder principal e a dor de negócio do projeto de vocês. Essa frase será a 'âncora' de todas as fases seguintes.



Espaço para o grupo preencher

A Diretoria de Supply Chain precisa melhorar o planejamento de abastecimento das lojas físicas, atualmente baseado em decisões que não acompanham adequadamente as variações da demanda ao longo do tempo. O projeto busca utilizar o histórico de vendas do Walmart para prever a demanda semanal e fornecer informações que apoiem decisões de planejamento de suprimentos e disponibilidade de produtos.

1 FASE 1 — Business View (Visão de Negócio)

45 minutos · mapeando intenções estratégicas, sem pensar em algoritmos ainda

Objetivo desta fase: mapear as intenções estratégicas do negócio e como o ML pode apoiar a tomada de decisão humana.

PASSO 1.1 Identificar o Ator de negócio

Pergunte: quem vai usar essa solução no dia a dia? Essa pessoa representa qual papel na organização?

💡 Exemplos de Atores

- *Streaming* → *Gerente de Retenção de Clientes*
- *Fraude* → *Gerente de Prevenção a Fraudes*
- *Saúde* → *Médico Oncologista*
- *Hospital (fluxo de atendimento)* → *Coordenador de Enfermagem*

📌 **ENTREGÁVEL DESTE PASSO:** Uma tabela com 1 linha por ator, contendo nome do ator e papel na organização (2 a 4 atores costuma bastar).

Nome do Ator	Papel na organização
<i>Gerentes de loja física</i>	Acompanhar o desempenho das vendas e utilizar as expectativas de demanda para apoiar decisões operacionais da loja.
<i>Diretoria de Supply Chain</i>	Planejar abastecimento, estoques e disponibilidade de produtos de acordo com a demanda esperada das lojas.
<i>Diretoria de FP&A</i>	Utilizar as projeções de vendas como informação para apoiar previsões financeiras, orçamento e planejamento de receitas.

PASSO 1.2 Definir o Goal (objetivo) e anotar expectativas de qualidade

Goal: o que esse ator quer alcançar, de forma mensurável. Indicador: a métrica numérica que mostra progresso desse Goal. Além disso, anotem (ainda de forma informal) frases do stakeholder sobre o que ele valoriza além do número principal — isso será formalizado como Softgoal só na Fase 2.

💡 Exemplo (streaming)

- *Goal: "Reduzir o cancelamento de assinaturas em 15% este ano"*
- *Indicador: taxa mensal de churn (%) — atual: 5% · meta: 4,25%*
- *Anotação informal de qualidade: "O time de retenção mencionou que a lista de clientes em risco precisa estar pronta toda segunda-feira de manhã, sem exceção."*

📌 **ENTREGÁVEL DESTE PASSO:** Para cada ator: o Goal, o Indicador (com valor atual e meta, se souberem) e 2–3 frases de qualidade esperada, em linguagem do negócio (ainda sem termos técnicos).

Ator	Goal (objetivo)	Indicador (métrica)	Expectativas de qualidade (informal)
Gerentes de loja física	Melhorar o planejamento operacional da loja com base na demanda esperada.	Faturamento Real x Faturamento Previsto	As previsões devem estar disponíveis antes do período previsto e apresentar nível de precisão suficiente para apoiar decisões da loja.
Diretoria de Supply Chain	Melhorar o planejamento de abastecimento das lojas de acordo com a demanda esperada.	Erro da previsão de vendas (WMAE). Meta: Redução de 15% em relação ao baseline.	A previsão deve representar adequadamente variações semanais das vendas, e apresentar desempenho superior ao baseline.
Diretoria de Controladoria	Melhorar a qualidade das projeções de vendas utilizadas no planejamento financeiro.	Faturamento Real x Faturamento Previsto	As previsões devem apresentar consistência e permitir agregação das estimativas para apoiar o planejamento financeiro.

PASSO 1.3 Decision Goal — a decisão que o ator precisa tomar

Uma decisão é sempre uma escolha entre opções — algo que alguém faz repetidamente. Se vocês não conseguem descrever uma escolha concreta, ainda não acharam a decisão certa.

Exemplos

- *Streaming*: "Decidir para quais clientes oferecer um desconto de retenção este mês" (opções: desconto A, desconto B, nenhuma ação)
- *Fraude*: "Decidir se uma transação deve ser bloqueada, sinalizada para revisão manual, ou aprovada"
- *Hospital*: "Decidir qual paciente deve ser atendido primeiro na triagem"

Cuidado com este erro comum

"Entender os clientes" não é uma decisão — é um desejo vago. Pergunte sempre: decidir entre o quê?

 **ENTREGÁVEL DESTE PASSO:** Uma frase por ator, no formato: '[Ator] precisa decidir [entre quais opções], com que frequência'.

- Gerentes de loja física: Decidir quais departamentos devem receber maior atenção no planejamento operacional em função das vendas previstas, semanalmente.
- Diretoria de Supply Chain: Decidir como priorizar o planejamento de abastecimento das lojas e departamentos de acordo com as vendas previstas, semanalmente.
- Diretoria de Controladoria: Decidir como atualizar as projeções de vendas utilizadas no planejamento financeiro e orçamentário, semanalmente.

PASSO 1.4 Question Goals — as perguntas que respondem à decisão

Desdobrem o Decision Goal em uma ou mais perguntas específicas que o modelo de ML precisa responder para apoiar a decisão. Especifiquem também o tipo de pergunta (quem/o quê/quando...), o tempo verbal (passado/presente/futuro) e a frequência necessária da resposta.

Exemplos

- *Streaming*: "Quais clientes têm alta chance de cancelar a assinatura nos próximos 30 dias?" → tipo: quem · tempo: futuro · frequência: mensal
- *Fraude*: "Essa transação específica é fraudulenta?" → tipo: o quê · tempo: presente · frequência: tempo real
- *Hospital*: "Qual paciente tem maior risco de piora nas próximas 2 horas?" → tipo: quem · tempo: futuro · frequência: tempo real


 **ENTREGÁVEL DESTE PASSO:** Para cada Decision Goal, uma ou mais Question Goals, indicando tipo, tempo verbal e frequência.

Question Goal (a pergunta)	Tipo	Tempo (passado/presente/futuro)	Frequência
Qual será a previsão de vendas por loja e departamento para a próxima semana?	Quanto	Futuro	Semanal
Quais lojas e departamentos terão maior e menor previsão de vendas na próxima semana?	Quais	Futuro	Semanal
Como as vendas previstas para a próxima semana se comparam ao histórico de vendas de cada loja e departamento?	Como	Futuro/Passado	Semanal



Entregável final da Fase 1

Desenhem (à mão, em slide, ou em ferramenta de diagramação) um diagrama conectando: Ator → Goal → Decision Goal → Question Goal(s), com os indicadores e as anotações informais de qualidade ao lado do Goal.



CHECKPOINT

Antes de seguir para a Fase 2, mostrem esse diagrama ao professor. Nenhum grupo deve avançar sem ter clareza total sobre o problema de negócio.

2 FASE 2 — Analytics Design View

45 minutos · traduzindo a pergunta de negócio em especificação técnica

Objetivo desta fase: traduzir as perguntas de negócio da Fase 1 em especificações técnicas de Machine Learning — e é aqui que formalizamos os Softgoals.

PASSO 2.1 Tipo de análise

Para cada Question Goal da Fase 1, classifiquem o tipo de análise necessária.

Tipo	O que faz	Exemplo
Preditiva	Prever um valor futuro ou desconhecido	Prever se o cliente vai cancelar
Descritiva	Resumir/explicar o conjunto de dados	Agrupar clientes em perfis de comportamento
Prescritiva	Recomendar a melhor ação entre opções	Recomendar qual desconto oferecer a cada cliente

 **ENTREGÁVEL DESTE PASSO:** Classificação (Preditiva/Descritiva/Prescritiva) para cada Question Goal, com uma frase justificando.

Question Goal	Tipo de análise	Justificativa
Qual será a previsão de vendas por loja e departamento para a próxima semana?	Preditiva	Utiliza dados históricos para estimar o valor das vendas em um período futuro.
Quais lojas e departamentos terão maior ou menor previsão de vendas na próxima semana?	Preditiva	Utiliza as vendas previstas para identificar lojas e departamentos com maiores ou menores valores esperados.
Como as vendas previstas para a próxima semana se comparam ao histórico de vendas de cada loja e departamento?	Preditiva	Compara as vendas previstas para um período futuro com o comportamento histórico de cada loja e departamento.

PASSO 2.2 Tarefa de ML e algoritmos candidatos

Desçam um nível de abstração: que tarefa técnica de ML corresponde a essa análise, e quais algoritmos poderiam resolvê-la? Listem do mais simples ao mais sofisticado — ainda não é hora de escolher 'o melhor'.

Exemplo (streaming — "prever cancelamento")

- *Tarefa de ML: Classificação Binária (vai cancelar / não vai cancelar)*
- *Algoritmos candidatos: regra manual (ex.: 'sem login há 20+ dias'), Regressão Logística, Random Forest, XGBoost, Rede Neural*

Se a tarefa parecer grande demais, quebrem em sub-tarefas (ex.: 'cancelamento voluntário' vs. 'cancelamento por falha de pagamento' — causas e dados diferentes).

 **ENTREGÁVEL DESTE PASSO:** Para cada Meta Analítica: a tarefa de ML correspondente e uma lista de 2–4 algoritmos candidatos.

Meta Analítica	Tarefa de ML	Algoritmos candidatos
Prever as vendas semanais futuras por loja e departamento	Regressão para séries temporais	Regressão Linear Múltipla, Random Forest Regressor, XGBoost Regressor e LSTM multivariada.

Meta Analítica	Tarefa de ML	Algoritmos candidatos
Identificar lojas e departamentos com maiores e menores vendas previstas	Regressão para séries temporais	Regressão Linear Múltipla, Random Forest Regressor, XGBoost Regressor e LSTM multivariada.
Estimar a variação futura das vendas em relação ao comportamento histórico	Regressão para séries temporais	Regressão Linear Múltipla, Random Forest Regressor, XGBoost Regressor e LSTM multivariada.

PASSO 2.3 Formalizar os Softgoals

Transformem as anotações informais de qualidade da Fase 1 (Passo 1.2) em Softgoals formais — requisitos de qualidade que vão pesar na escolha do algoritmo.

💡 Exemplos, com a origem no negócio

- "Não quero muitos alarmes falsos" (fraude) → Softgoal: Baixa taxa de Falso Positivo / Alta Precisão
- "Preciso entender o motivo da recomendação" (saúde) → Softgoal: Explicabilidade
- "A lista precisa estar pronta toda segunda de manhã" (streaming) → Softgoal: Baixa latência / lote compatível com o prazo
- Softgoals técnicos que o time de dados pode trazer, mesmo sem o stakeholder ter pedido: Custo de treino/operação, Privacidade dos dados, Robustez a mudanças de comportamento (drift)

📌 **ENTREGÁVEL DESTE PASSO:** Lista de 3–5 Softgoals formais, cada um citando de qual anotação da Fase 1 ele se origina (ou indicando que é um softgoal técnico adicional).

Softgoal	Origem (frase do stakeholder ou 'técnico')
Alta qualidade preditiva	Supply Chain: Espera-se uma previsão de vendas suficientemente precisa para apoiar o planejamento.
Robustez às variações da demanda	Supply Chain e Gerentes de Loja: a previsão deve representar adequadamente as variações das vendas entre períodos, lojas e departamentos.
Disponibilidade da previsão no prazo	Gerentes de Loja / Supply Chain: as previsões devem estar disponíveis semanalmente para apoiar as decisões de planejamento.

PASSO 2.4 Vincular Softgoals a métricas de ML tangíveis

🌟 O "pulo do gato" do GR4ML

Todo Softgoal precisa virar uma métrica técnica mensurável, ou ele fica bonito no papel e não influencia nada na prática. Alunos de computação tendem a otimizar só a Acurácia — mas se o negócio exige Explicabilidade, um modelo caixa-preta sem SHAP/LIME viola um requisito de negócio, mesmo acertando mais.

💡 Exemplos de vínculo Softgoal → Métrica

- Fraude: "Evitar perturbar clientes inocentes" → alta Precisão / baixa taxa de Falso Positivo
- Saúde: "Explicabilidade" → uso obrigatório de SHAP/LIME, ou restrição a modelos interpretáveis

• *Streaming*: "Compatível com o prazo semanal" → tempo de inferência em lote < 2h para toda a base

 **ENTREGÁVEL DESTE PASSO:** Uma tabela cruzando Algoritmos (Passo 2.2) × Softgoals (Passo 2.3), com a métrica usada em cada cruzamento, e uma conclusão de qual algoritmo o grupo escolheria.

Algoritmo	Softgoal 1 (métrica)	Softgoal 2 (métrica)	Softgoal 3 (métrica)
Regressão Linear Múltipla	WMAE	Estabilidade do erro entre períodos	Tempo de execução
Random Forest Regressor	WMAE	Estabilidade do erro entre períodos	Tempo de execução
XGBoost Regressor	WMAE	Estabilidade do erro entre períodos	Tempo de execução
LSTM	WMAE	Estabilidade do erro entre períodos	Tempo de execução

Conclusão do grupo — qual algoritmo escolheriam e por quê:

Os algoritmos serão comparados quanto à qualidade e confiabilidade das previsões e ao custo computacional. A escolha será realizada após os testes, considerando o melhor equilíbrio entre desempenho preditivo e complexidade.

PASSO 2.5 Conectar de volta ao indicador de negócio

Fechem o ciclo com a Fase 1: expliquem como a melhoria esperada no modelo se traduz em melhoria no indicador de negócio.

Exemplo (streaming)

• "Se o modelo identificar corretamente 80% dos clientes que vão cancelar, e a campanha de retenção converter 30% deles, esperamos reduzir o churn mensal de 5% para ~4,2%."

 **ENTREGÁVEL DESTE PASSO:** Um parágrafo curto conectando o desempenho esperado do modelo ao Indicador definido no Passo 1.2.

Espera-se que o modelo reduza o erro das previsões (WMAE) em pelo menos 15% em relação ao baseline, aproximando as vendas previstas das vendas realizadas, aproxime as vendas previstas das vendas realizadas. Previsões mais precisas devem fornecer informações mais confiáveis para o planejamento de Supply Chain e contribuir para reduzir o desvio entre o faturamento previsto e o realizado, indicador utilizado pelos Gerentes de Loja e FP&A.

CHECKPOINT

Antes de seguir para a Fase 3, garantam que cada Softgoal tem uma métrica associada — não deixem nenhum 'bonito no papel'.

3 FASE 3 — Data Preparation View

45 minutos · conectando os algoritmos às fontes de dados reais

Objetivo desta fase: conectar os algoritmos escolhidos às fontes de dados reais necessárias para treiná-los e alimentá-los.

PASSO 3.1 Fontes de dados (entidades e atributos)

Identifiquem as entidades e atributos do mundo real necessários para o modelo — mesmo que hipotéticos.

Exemplo (streaming)

- *Cadastro do Cliente: nome, idade, cidade, data de assinatura*
- *Histórico de Visualização: o quê assistiu, quando, por quanto tempo*
- *Atendimentos ao Suporte: data, motivo, se foi resolvido*
- *Logs de Pagamento: forma de pagamento, se houve falha de cobrança*

 **ENTREGÁVEL DESTE PASSO:** Lista das tabelas/fontes de dados brutos, com 3–5 campos principais de cada uma.

Fonte de dados (tabela)	Principais campos/atributos
<i>Vendas</i>	Store, Dept, Date, Weekly_Sales, IsHoliday
<i>Lojas</i>	Store, Type, Size
<i>Condições econômicas</i>	Temperature, Fuel_Price, CPI, Unemployment
<i>Promoções / Markdowns</i>	MarkDown1, MarkDown2, MarkDown3, MarkDown4, MarkDown5

PASSO 3.2 Data Operations — transformações

Descrevam as transformações necessárias para os dados brutos virarem features (colunas prontas para o modelo).

Tipos de tratamento, com exemplos

- *Tratamento de nulos: preencher ou descartar registros incompletos*
- *Normalização: colocar variáveis em escalas comparáveis*
- *One-Hot Encoding: transformar categorias (ex.: forma de pagamento) em colunas binárias*
- *Agregações temporais: calcular 'horas assistidas por semana' a partir de logs brutos*
- *Integração: juntar tabelas usando o ID do cliente como chave*

 **ENTREGÁVEL DESTE PASSO:** Lista numerada das transformações aplicadas, na ordem em que ocorrem, do dado bruto até a tabela final.

Nº	Transformação aplicada	Tabela(s) de origem
1	Tratamento e ordenação temporal: converter Date para formato de data, ordenar os registros cronologicamente e tratar valores ausentes, especialmente nos campos de Markdown.	Dataset Walmart
2	Preparação das variáveis: codificar variáveis categóricas/binárias e padronizar ou normalizar as variáveis numéricas utilizadas pelo modelo.	Dataset Walmart
3	Construção das séries temporais: organizar Weekly_Sales cronologicamente por Store e Dept e criar janelas temporais para utilizar vendas anteriores na previsão da venda seguinte.	Dataset Walmart
4	Separação e preparação para treinamento: dividir os dados em treino e teste preservando a ordem temporal e converter as variáveis para estruturas numéricas adequadas aos modelos.	Dataset Walmart

PASSO 3.3 Dataset final e Pipeline

Mostrem a 'tabela final' que o modelo realmente usa — uma linha por unidade de análise, uma coluna por feature — e conectem-na diretamente às tarefas de ML da Fase 2.


Exemplo de dataset preparado (streaming)

• Colunas: *Cliente_ID* | *Dias sem logar* | *Horas assistidas/semana* | *Nº reclamações (3 meses)* | *Já teve falha de pagamento?* | *Cancelou (rótulo)*

 **ENTREGÁVEL DESTES PASSOS:** Exemplo de tabela final (pode ser fictício, poucas linhas) + um diagrama simples de pipeline: Fontes brutas → Transformações → Dataset Final → Algoritmo.

Coluna (feature)	Descrição	De qual fonte / transformação vem
<i>Store</i>	Identificador da loja	Dados de Lojas
<i>Dept</i>	Identificador do departamento	Dados de Vendas
<i>Date</i>	Data correspondente à observação semanal	Dados de Vendas → tratamento de data
<i>Histórico de Weekly_Sales</i>	Valores das vendas das semanas anteriores utilizados como sequência de entrada	Weekly_Sales → criação das janelas temporais
<i>IsHoliday</i>	Indica se a semana está associada a um feriado	Dados de Vendas → codificação

Coluna (feature)	Descrição	De qual fonte / transformação vem
<i>Type</i>	Tipo da loja	Dados de Lojas → codificação categórica
<i>Size</i>	Tamanho da loja	Dados de Lojas → preparação da variável numérica
<i>Temperature</i>	Temperatura registrada no período	Condições externas → preparação/padronização
<i>Fuel_Price</i>	Preço do combustível no período	Condições econômicas → preparação/padronização
<i>CPI</i>	Índice de preços ao consumidor	Condições econômicas → preparação/padronização
<i>Unemployment</i>	Taxa de desemprego	Condições econômicas → preparação/padronização
<i>MarkDown1-5</i>	Variáveis relacionadas às ações de markdown/promoções	Promoções/Markdowns → tratamento dos valores ausentes
<i>Weekly_Sales (target)</i>	Venda semanal futura que o modelo deverá prever	Weekly_Sales → target definido pela janela temporal



CHECKPOINT

Um colega de fora do grupo, lendo o pipeline, deveria entender de onde vem cada coluna da tabela final.

Ferramentas recomendadas

Como o GR4ML estende conceitos do i* (iStar), os alunos podem utilizar:

- **Ferramentas de diagramação geral:** Miro, Lucidchart ou Draw.io, criando uma legenda própria para os elementos do GR4ML:
 - Retângulos arredondados → Goals (Strategic Goal, Decision Goal, Question Goal)
 - Nuvens → Softgoals
 - Hexágonos → Tasks/Algoritmos
- **Ferramentas acadêmicas baseadas em i*:** para quem preferir mais formalismo, a piStar tool, adaptada com estereótipos do GR4ML, ajuda na modelagem orientada a objetivos.

Verificação final

Antes de entregar, completem esta frase única, sem inventar nada que não esteja documentado nas fases anteriores. Se alguma parte não existir no material do grupo, é sinal de que uma fase ficou incompleta — voltem e revisem.

Frase de verificação

"Para ajudar [Ator] a decidir [Decision Goal], respondendo à pergunta [Question Goal], vamos usar [Algoritmo], que satisfaz os softgoals [Softgoals] medidos por [Métricas], usando os dados [Dataset Preparado] vindos de [Fontes de Dados]. Isso deve impactar o indicador [Indicador] em [magnitude esperada]."

Preenchem a frase com o projeto de vocês

Para ajudar a Diretoria de Supply Chain a decidir como priorizar o planejamento de abastecimento das lojas e departamentos, respondendo à pergunta sobre quais serão as vendas previstas por loja e departamento para a próxima semana, serão avaliados modelos de regressão multivariada para séries temporais, considerando os softgoals de qualidade preditiva, robustez às variações das vendas e disponibilidade da previsão no prazo, medidos por WMAE, estabilidade do erro entre períodos e tempo de execução. Os modelos utilizarão o dataset preparado a partir dos dados de vendas, lojas, condições econômicas e promoções do Walmart. A melhoria das previsões deverá reduzir o WMAE em 15% em relação ao baseline, diminuindo o desvio entre as vendas previstas e realizadas e apoiando, assim, o planejamento de abastecimento.



FASE 4 — Dos Modelos aos Requisitos

30 minutos · transformando os diagramas GR4ML em uma lista de requisitos formal

Até aqui, o grupo construiu três diagramas/modelos. Mas um diagrama, sozinho, ainda não é um documento de requisitos — é preciso 'traduzir' cada elemento do modelo em frases claras, testáveis, que um time de engenharia consiga implementar e verificar. Essa tradução segue sempre o mesmo caminho: cada elemento do GR4ML já modelado nas fases anteriores dá origem a um tipo específico de requisito.



Por que isso importa

Um Decision Goal ou um Softgoal, por si só, é uma intenção — não uma instrução que um desenvolvedor consiga implementar ou testar. A elicitação só termina de fato quando a intenção vira um requisito redigido de forma objetiva, rastreável até o elemento do modelo que o originou.

Mapa de tradução: do elemento do GR4ML ao tipo de requisito

Elemento já modelado	Tipo de requisito gerado	Pergunta-guia para redigir
Decision Goal + Question Goal + Insight (Fase 1)	Requisito Funcional (RF)	O que exatamente o sistema precisa calcular ou entregar?
Softgoal + Métrica associada (Passo 2.3–2.4)	Requisito Não-Funcional (RNF)	Que qualidade o sistema deve garantir, e como ela será medida?
Entidades + Dataset Preparado + Transformações (Fase 3)	Requisito de Dados (RD)	Que dados precisam ser coletados, integrados e tratados, e de onde vêm?
Indicador (Passo 1.2)	Critério de Aceitação do conjunto de requisitos	Como saberemos, no negócio, que os requisitos implementados geraram valor real?

PASSO 4.1 Redigir os Requisitos Funcionais (RF)

Um Requisito Funcional descreve uma capacidade que o sistema deve ter. Ele nasce da junção entre a decisão (Decision Goal), a pergunta que a apoia (Question Goal) e o insight que a responde (Fase 1).

💡 Modelo de frase (template)

- "O sistema deve [ação/cálculo], a partir de [dados de entrada], para permitir que [Ator] [decisão apoiada]."

💡 Exemplo preenchido (streaming)

- "O sistema deve calcular uma pontuação de risco de cancelamento (0 a 100) para cada cliente ativo, a partir do histórico de uso, suporte e pagamento dos últimos 12 meses, atualizada semanalmente, para permitir que o Gerente de Retenção decida quais clientes recebem desconto."

🔗 **ENTREGÁVEL DESTE PASSO:** Um Requisito Funcional (RF) redigido para cada Insight identificado na Fase 1, seguindo o template acima.

ID	Requisito Funcional (RF)	Origem no modelo (Insight/Decision Goal)
RF-01	O sistema deve gerar semanalmente a previsão de vendas por loja e departamento, a partir do histórico de vendas e das variáveis disponíveis no dataset, para apoiar o planejamento operacional e de abastecimento.	Prever as vendas da próxima semana / Decision Goals dos Gerentes de Loja e Supply Chain
RF-02	O sistema deve identificar as lojas e os departamentos com maiores e menores vendas previstas para a próxima semana, a partir das previsões geradas pelo modelo, para apoiar a priorização das decisões de planejamento	Identificar lojas e departamentos com maiores e menores vendas previstas / Decision Goals dos Gerentes de Loja e Supply Chain
RF-03	O sistema deve comparar as vendas previstas para a próxima semana com o histórico de vendas por loja e departamento, permitindo avaliar a variação esperada e apoiar a atualização das projeções de planejamento.	Comparar a previsão com o comportamento histórico / Decision Goal de FP&A

PASSO 4.2 Redigir os Requisitos Não-Funcionais (RNF)

Um Requisito Não-Funcional descreve uma qualidade que o sistema deve garantir — nasce diretamente dos Softgoals formalizados e das métricas que vocês vincularam a eles no Passo 2.4.

💡 Modelo de frase (template)

- "O sistema deve garantir [qualidade/softgoal], medida por [métrica], com [meta/limite]."

💡 Exemplos preenchidos

- "O sistema deve fornecer explicabilidade para cada predição de risco, medida pela disponibilidade de valores SHAP por cliente." (origem: Softgoal Explicabilidade)
- "O sistema deve processar toda a base de clientes em lote em menos de 2 horas." (origem: Softgoal Baixa latência / prazo semanal)

🔗 **ENTREGÁVEL DESTE PASSO:** Um Requisito Não-Funcional (RNF) redigido para cada Softgoal formalizado no Passo 2.3, usando a métrica definida no Passo 2.4.

ID	Requisito Não-Funcional (RNF)	Origem no modelo (Softgoal/Métrica)
RNF-01	O sistema deve garantir alta qualidade preditiva, medida pelo WMAE, priorizando o modelo que apresentar o menor valor de WMAE entre os candidatos avaliados.	Alta qualidade preditiva / WMAE
RNF-02	O sistema deve garantir robustez às variações da demanda, medida pela variação do WMAE entre diferentes períodos, priorizando o modelo que apresentar menor variação do erro.	Robustez às variações da demanda / Variação do WMAE entre períodos
RNF-03	O sistema deve garantir a disponibilidade da previsão no prazo, medida pelo tempo de execução, de forma que a previsão esteja disponível antes do ciclo semanal de planejamento.	Disponibilidade da previsão no prazo / Tempo de execução
RNF-04	O sistema deve calcular o erro preditivo utilizando a métrica WMAE (Weighted Mean Absolute Error), garantindo que o erro das semanas de feriados principais (Super Bowl, Labour Day, Thanksgiving e Christmas) receba um peso multiplicador maior ($Sw_i = 5$) em relação às semanas normais ($Sw_i = 1$).	Alta qualidade preditiva / Regra de avaliação de negócio

PASSO 4.3 Redigir os Requisitos de Dados (RD)

Um Requisito de Dados descreve o que precisa ser coletado, integrado ou tratado — nasce das Entidades, do Dataset Preparado e das transformações mapeadas na Fase 3.

Modelo de frase (template)

- "O sistema deve integrar/coletar/tratar [dado], proveniente de [fonte], aplicando [transformação], para alimentar [RF correspondente]."

Exemplo preenchido (streaming)

- "O sistema deve integrar dados de Cadastro do Cliente, Histórico de Visualização, Atendimentos ao Suporte e Pagamentos, tratando valores nulos e agregando o histórico de visualização em 'horas assistidas por semana', para alimentar o requisito RF-01."

 **ENTREGÁVEL DESTE PASSO:** Um ou mais Requisitos de Dados (RD), cobrindo as fontes e transformações da Fase 3, cada um referenciando o RF que ele alimenta.

ID	Requisito de Dados (RD)	RF que este dado alimenta
RD-01	O sistema deve tratar os dados de Vendas, Lojas, Condições Econômicas e Promoções/Markdowns do dataset Walmart, incluindo o tratamento de valores ausentes, a conversão da variável Date e a ordenação cronológica dos registros.	RF-01, RF-02 e RF-03
RD-02	O sistema deve preparar as variáveis do dataset, aplicando a codificação das variáveis categóricas/binárias e a padronização ou normalização das variáveis numéricas utilizadas pelos modelos.	RF-01
RD-03	O sistema deve organizar Weekly_Sales cronologicamente por Store e Dept, construindo janelas temporais com as observações anteriores para prever as vendas da semana seguinte e separando os dados de treino e teste de forma temporal.	RF-01, RF-02 e RF-03
RD-04	O sistema deve manter a identificação das semanas de feriado por meio da variável IsHoliday, permitindo a aplicação da ponderação definida no cálculo do WMAE	RF-01

PASSO 4.4 Definir o Critério de Aceitação (fechando o ciclo com o negócio)

Por fim, reconectem tudo ao Indicador de negócio definido lá no Passo 1.2 — é isso que prova que os requisitos, uma vez implementados, geram valor real, e não apenas um modelo tecnicamente correto.

Modelo de frase (template)

• "Este conjunto de requisitos será considerado bem-sucedido se [indicador] atingir [meta], observado em [período/frequência]."

Exemplo preenchido (streaming)

• "Este conjunto de requisitos será considerado bem-sucedido se a taxa mensal de churn cair de 5% para 4,25% em até 6 meses após o lançamento."

 **ENTREGÁVEL DESTE PASSO:** Uma frase de critério de aceitação, conectando os RF/RNF/RD ao Indicador de negócio da Fase 1.

Este conjunto de requisitos será considerado bem-sucedido se, nas avaliações semanais, o modelo selecionado alcançar uma redução de, no mínimo, 15% no erro de previsão de vendas, medido pelo WMAE, em relação ao baseline. Essa melhoria deverá aproximar as vendas previstas das realizadas e contribuir para o planejamento de Supply Chain.

Como reconhecer um requisito bem escrito

Use sempre 'o sistema deve...' (nunca 'seria bom se' ou 'o ideal seria'). Um requisito por frase — não amarrem duas exigências na mesma sentença. Ele precisa ser testável: alguém de fora do grupo deveria conseguir dizer, olhando o sistema pronto, se aquele requisito foi ou não atendido. E ele precisa ser rastreável: sempre cite de qual elemento do modelo GR4ML (Decision Goal, Softgoal, Entidade) aquele requisito se originou — é essa rastreabilidade que prova que a elicitação foi feita de ponta a ponta, e não inventada na hora de escrever o documento.

CHECKPOINT

A tarefa só está completa quando existe uma lista numerada de RFs, RNFs e RDs, cada um rastreável a um elemento específico dos modelos das Fases 1 a 3, e um critério de aceitação ligado ao Indicador de negócio.

Estrutura do documento a ser entregue

- 1. Contexto do projeto (Fase 0)
- 2. Diagrama e tabelas da Business View (Fase 1)
- 3. Tabelas de tarefas/algoritmos/softgoals/métricas da Analytics Design View (Fase 2)
- 4. Diagrama de pipeline da Data Preparation View (Fase 3)
- 5. Frase de verificação final preenchida
- 6. Lista consolidada de Requisitos Funcionais, Não-Funcionais e de Dados, com critério de aceitação (Fase 4)
- 7. Reflexão crítica (½ página): o ML era realmente necessário aqui? O que a formalização dos Softgoals e a tradução para requisitos revelaram que não estava claro na conversa inicial com o stakeholder?

Reflexão crítica do grupo

O uso de Machine Learning mostra-se pertinente neste projeto porque a previsão de vendas não depende apenas do comportamento histórico da própria série. O dataset reúne diferentes variáveis que podem estar relacionadas às vendas, como características das lojas, feriados, promoções, temperatura e indicadores econômicos. Dessa forma, a utilização de uma abordagem multivariada permite considerar simultaneamente essas informações na construção das previsões, em vez de analisar somente a evolução passada das vendas.

A aplicação do GR4ML também mostrou que a previsão, isoladamente, não representa o objetivo final do projeto. A informação gerada precisa apoiar decisões concretas de diferentes áreas. Os Gerentes de Loja precisam compreender o comportamento esperado das vendas para apoiar o planejamento operacional, Supply Chain necessita dessas informações para o planejamento de abastecimento e FP&A pode utilizá-las como suporte às projeções financeiras.

A formalização dos Softgoals evidenciou ainda que a solução não deverá ser avaliada somente pela qualidade preditiva. A robustez diante das variações da demanda e a disponibilidade das previsões dentro do prazo necessário também são requisitos relevantes e deverão ser considerados na avaliação da solução.

Por fim, a tradução do problema em requisitos funcionais, não funcionais e de dados tornou explícitos aspectos que não estavam claros inicialmente, principalmente a relação entre as variáveis disponíveis, as transformações necessárias e as decisões que serão apoiadas pelas previsões. O GR4ML permitiu, portanto, estruturar o projeto antes da modelagem, estabelecendo uma ligação clara entre necessidade de negócio, dados, requisitos e futura solução de Machine Learning.